11 - Fitxers

November 20, 2015

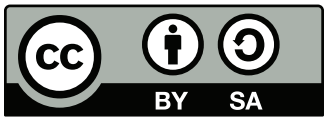

Authors : *Sonia Estradé*
José M. Gómez
Ricardo Graciani
Frank Güell
Manuel López
Xavier Luri
Josep Sabater

Moltes vegades és necessari enmagatzemnar i demanar dades per no perdre-les. Python permet guardar la informació en un fitxer i llegir-la quan sigui necessari.

1 Funcions màgiques al Notebook

iPython Notebook té un conjunt de 'magic functions' que les podeu cridar des del notebook **cell of code**. Hi ha dos tipus: line-oriented (%) and cell-oriented (%%).

La funció %lsmagic s'utilitza per llistar totes les funcions màgiques, i mostrarà els dos tipus correctament definides:

```
In [1]: %lsmagic
```

```
Out[1]: Available line magics:
        %alias  %alias_magic  %autocall  %automagic  %autosave  %bookmark  %cat  %cd  %clear  %colors  %

        Available cell magics:
        %%!  %%HTML  %%SVG  %%bash  %%capture  %%debug  %%file  %%html  %%javascript  %%latex  %%perl  %

        Automagic is ON, % prefix IS NOT needed for line magics.
```

Per exemple, podem utilitzar en Unix/Linux el comand `pwd` per mostrar el directori de treball actual:

```
In [2]: %pwd
```

```
Out[2]: '/Users/chema/Documents/Clases/Informatica/Repositori/Python/Apunts 2015-2016/Catala/11 - Fitxe
```

A les properes seccions, utilitzarem més funcions màgiques, especialment les relacionades amb fitxers. Podeu trobar més exemples aquí.

2 Treballant amb dades de text bàsiques

El primer pas és llegir o escriure dades desestructurades en un fitxer.

2.1 Llegint un fitxer de text simple

Primer creem un fitxer simple, utilitzant la funció màgica cell-oriented %%file:

```
In [3]: %%file test.txt
        This is a text file created to check
        Python file read and write.
```

```
Writing test.txt
```

Per llegir el fitxer, en primer lloc cal obrir-lo:

```
In [4]: inputFile = open('test.txt', 'r')

        print(inputFile)
```

```
<_io.TextIOWrapper name='test.txt' mode='r' encoding='UTF-8'>
```

Els paràmetres són:

- name of the file.
- read mode (`r`), we can also use binary mode (`b`) to avoid problems with text conversion.
- the optional universal line-end mode (`U`) to be able to interchange documents between operating systems.

A continuació llegim les línies del fitxer:

```
In [5]: file_in = inputFile.readlines()
        print(file_in)

        for line in file_in:
            print(line, end='')
```

```
['This is a text file created to check\n', 'Python file read and write.']
This is a text file created to check
Python file read and write.
```

A continuació el fitxer s'ha de tancar:

```
In [6]: inputFile.close()
```

2.2 Escribint un fitxer de text simple

Ara seguint un procediment similar escriurem un fitxer desestructurat.

```
In [7]: outputFile = open('secondTest.txt', 'w')
```

```
In [8]: outputFile.write('Another file\n')
        outputFile.write('A second line\n')
```

```
Out[8]: 14
```

```
In [9]: outputFile.close()
```

```
In [10]: %less secondTest.txt
```

2.3 La sentència `with`

D'avegades els fitxers no es poden escriure o llegir apropiadament i apareixen errors. I si apareix un error, el fitxer s'ha de tancar sempre. Per evitar problemes, python té la sentència `with` .

```
In [11]: with open('thirdTest.txt', 'w') as outputFile:
             for i in range(10):
                 outputFile.write('New test. ' +
                                  str(i) + '\n')

In [12]: %less thirdTest.txt

In [13]: outputFile.closed

Out[13]: True
```

El fitxer s'ha escrit i tancat.

```
In [14]: with open('thirdTest.txt', 'r') as inputFile:
             print(inputFile.read(), end = '')

New test. 0
New test. 1
New test. 2
New test. 3
New test. 4
New test. 5
New test. 6
New test. 7
New test. 8
New test. 9
```

3 Treballant amb moduls d'ajuda

Ara intentarem escriure dades. Per exemple, podem crear dues fileres de dades:

```
In [15]: import math

         x = [point/10. for point in range(0, 100)]
         y = [math.sin(x_point) for x_point in x]

In [16]: %pylab inline
         %config InlineBackend.figure_format = 'svg'

         import matplotlib.pyplot as plt

         str_title = 'f(x) = sin(x)'
         fig1 = plt.figure()
         fig1.suptitle(str_title, fontsize=14)
         fig1_ax = fig1.add_subplot(1, 1, 1)
         fig1_ax.set_xlabel('x')
         fig1_ax.set_ylabel('sin(x)')
         fig1_ax.grid(True, which='both')

         fig1_ax.plot(x, y)
```

```
Populating the interactive namespace from numpy and matplotlib
```

```
Out[16]: [<matplotlib.lines.Line2D at 0x11354e400>]
```

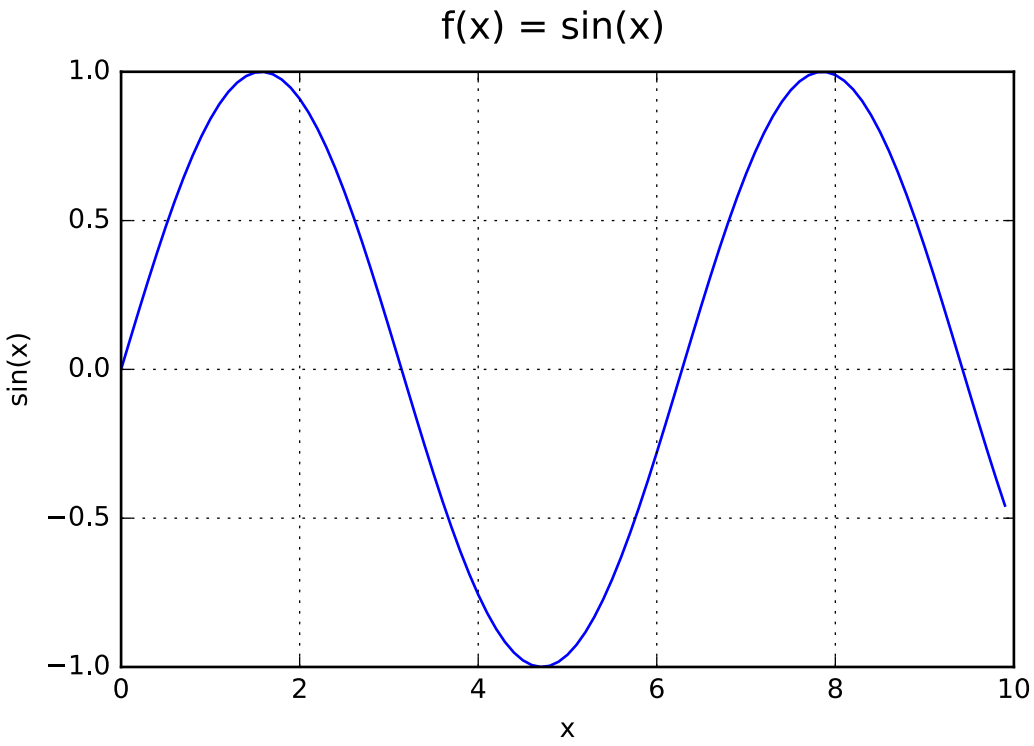

3.1 Escribint un fitxer amb `json`

La manera més simple d'enmagatzemar dades des de Python és utilitzant el mòdul `json`. En aquest cas, només cal utilitzar la funció `dump` amb la variable a enmagatzemar com a primer argument i el fitxer com a segon:

```
In [17]: import json

         with open('sin.json', 'w') as outputFile:
             json.dump({'x': x, 'y': y}, outputFile, sort_keys=True)
```

Amb això, s'ha creat un fitxer que conté la informació des de x a y.

```
In [18]: %less sin.json
```

Però no és fàcil entendre el fitxer.

3.2 Llegint el fitxer `json`

Ara és pot demanar amb la funció `load`, la qual retorna els continguts de la variable. És important tenir en compte que l'ordre de llegir les dades ha de ser el mateix en el que s'han enmagatzemat:

```
In [19]: with open('sin.json', 'r') as inputFile:
             data = json.load(inputFile)
             xf = data['x']
             yf = data['y']

In [20]: import matplotlib.pyplot as plt

         plt.plot(xf, yf, x, y)

Out[20]: [<matplotlib.lines.Line2D at 0x113632b00>,
          <matplotlib.lines.Line2D at 0x113632cc0>]
```

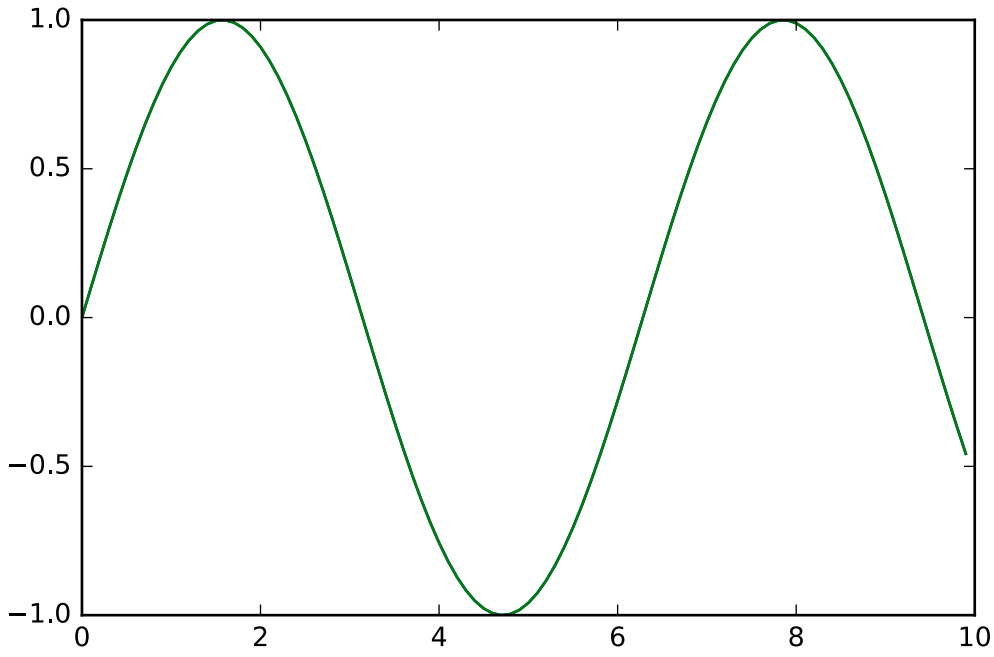

La dificultat més gran d'aquest format és que només Python ho enten. Per aquesta raó, si desitjem intercanviar les dades, serà necessari utilitzar un format estructurat.

4 Dades estructurades

La manera bàsica serà treballant amb fitxers `txt` :

4.1 Treballant amb l'estructurat `txt`

Primer cal definir el format. Per simplificar com llegir-ho, l'escriurem de forma similar a com ho fariem en una taula. Les columnes estaran separades per tabuladors:

```
In [21]: with open('sin.txt', 'w') as outputFile:
             for dataX, dataY in zip(x, y):
                 outputFile.write(str(dataX) +
                                  "\t" + str(dataY) +
                                  "\n")
```

Les dades s'enmagatzemaran entre línies, la x a la primera columna i la y a la segona, i separats per un tabulador.

```
In [22]: %less sin.txt
```

La dificultat més gran és llegir de nou les dades, ja que s'han de decodificar. Primer s'obre el fitxer i totes le línies de text són demanades:

```
In [23]: with open('sin.txt', 'r') as inputFile:
             lines = []

             # The lines are read from the file
             for line in inputFile.readlines():

                 # The line is stored in the list
                 lines.append(line)
```

Cad línia té dos valors, la x i la y, encara que barrejades amb la tabulació i la nova línia:

```
In [24]: lines[1]

Out[24]: '0.1\t0.09983341664682815\n'
```

Primer és necessari separar els dos valors. Per això cal dos passos, en primer lloc cal treure els innecessaris caràcters espais (`strip`):

```
In [25]: lineStripped = lines[0].strip()

         lineStripped

Out[25]: '0.0\t0.0'
```

El segon pas serà `split` la línia en dues cel·les `\t`.

```
In [26]: lineSplitted = lineStripped.split('\t')

         lineSplitted

Out[26]: ['0.0', '0.0']
```

Finalment, serà necessari convertir les cadenes en valors flotants, utilitzant la funció `float`:

```
In [27]: float(lineSplitted[0])

Out[27]: 0.0
```

Amb aquest procés, les dades són demanades:

```
In [28]: xf = []
         yf = []

         for line in lines:
             # The line is stripped taking out all the unnecesary characters
             lineStripped = line.strip()

             # The line is splitted using the tab character
             lineSplitted = lineStripped.split('\t')

             xf.append(float(lineSplitted[0]))
             yf.append(float(lineSplitted[1]))
```

El procés total es pot agrupar:

```
In [29]: xf = []
         yf = []

         with open('sin.txt', 'r') as inputFile:
             for line in inputFile.readlines():
                 lineStripped = line.strip()
                 lineSplitted = lineStripped.split('\t')

                 xf.append(float(lineSplitted[0]))
                 yf.append(float(lineSplitted[1]))
```

Ara les dades es poden mostrar:

```
In [30]: import matplotlib.pyplot as plt

         plt.plot(xf, yf)

Out[30]: [<matplotlib.lines.Line2D at 0x113738710>]
```

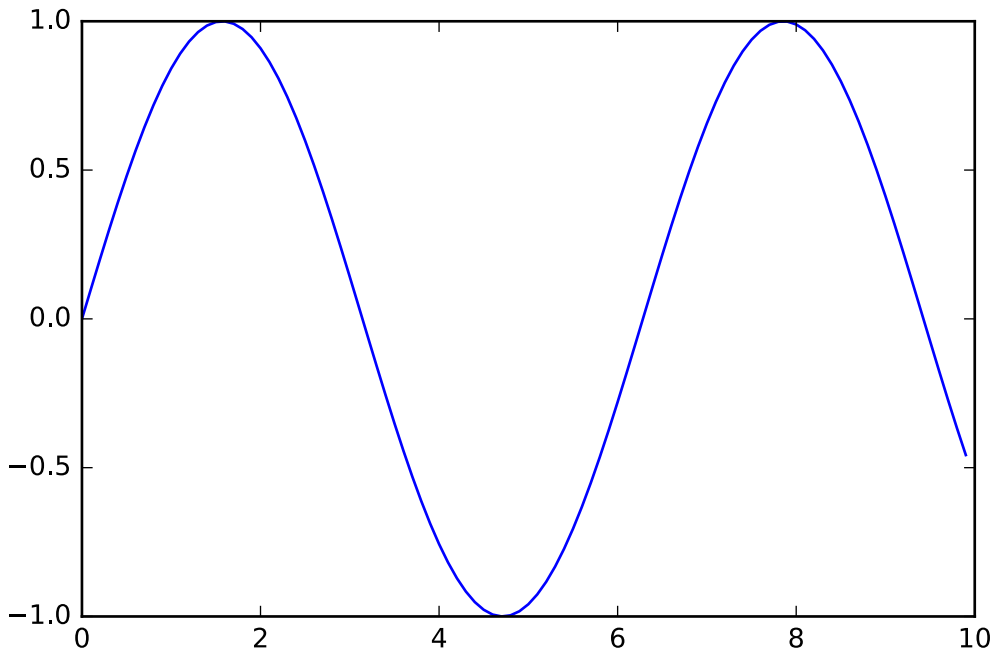

Això implica que per cada fitxer, és necessari escriure el codi strip i split i processar la informació. Python dóna una alternativa.

4.2 Utilitzant el mòdul `csv`

Les mateixes operaciones es poden seguir, però amb el mòdul csv, que fa fitxers compatibles amb Excel o Calc. En aquest cas, necessitem utilitzar l'ordinador local, per estar segurs que ambdós programes ententen correctament els continguts dels fitxers. Veiem un exemple:

```
In [31]: import locale

         locale.setlocale(locale.LC_ALL, '')

         with open('sinCSV.csv', 'w') as outputFile:
             for dataX, dataY in zip(x, y):
                 outputFile.write('{:n};{:n}\n'.format(dataX, dataY))

In [32]: %less sinCSV.csv
```

El fitxer separa les columnes amb semi-comes. Ara ho podem llegir amb Excel o Calc.

Podem fer el mateix process, però utilitzant el mòdul csv. En aquest cas, per estar segur que tenim el desitjat format natiu, hem de modificar lleugerament el procediment:

```
In [33]: import locale
         import csv

         locale.setlocale(locale.LC_ALL, '')

         with open('sinCSV.csv', 'w') as outputFile:
             writer = csv.writer(outputFile, delimiter=';')
             dataX = [locale.str(value) for value in x]
             dataY = [locale.str(value) for value in y]
             writer.writerows(zip(dataX, dataY))
```

El resultat és equivalent. També podem llegir el fitxer:

```
In [34]: %less sinCSV.csv
```

Això és fàcil de fer amb el mòdul `csv`:

```
In [35]: import csv

         sinList = []

         with open('sinCSV.csv', 'r') as csvfile:
             sinReader = csv.reader(csvfile,
                                    delimiter=';',
                                    quotechar='"')
             for row in sinReader:
                 sinList.append(row)

In [36]: len(sinList[0])

Out[36]: 2
```

En aquest cas les cel·les estan completament separades:

```
In [37]: type(sinList[0][0])

Out[37]: str
```

Ara els valors es poden convertir a flotants com en el cas previ. Per simplificar podem utilitzar:

```
In [38]: data = [[float(cell) for cell in row] for row in sinList]
```

```
---------------------------------------------------------------------------

ValueError                                Traceback (most recent call last)

<ipython-input-38-d02b43a28160> in <module>()
----> 1 data = [[float(cell) for cell in row] for row in sinList]


<ipython-input-38-d02b43a28160> in <listcomp>(.0)
----> 1 data = [[float(cell) for cell in row] for row in sinList]


<ipython-input-38-d02b43a28160> in <listcomp>(.0)
----> 1 data = [[float(cell) for cell in row] for row in sinList]


ValueError: could not convert string to float: '0,1'
```

Apareix un problema nou, l'ús de la coma enlloc del punt, no permet convertir la cadena a flotant. Això es pot solucionar utilitzant el mòdul `locale` altre cop. Hem convertit les cadenes a flotants utilitzant la funció `atof` function de locale:

```
In [39]: data = [[locale.atof(cell) for cell in row] for row in sinList]
```

Ara aquestes dades es poden transferir a dues llistes:

```
In [40]: xf = []
         yf = []

         with open('sinCSV.csv', 'r') as inputFile:
             sinReader = csv.reader(inputFile, delimiter=';', quotechar='"')
             for row in sinReader:
                 xf.append(locale.atof(row[0]))
                 yf.append(locale.atof(row[1]))

In [41]: %config InlineBackend.figure_format = 'svg'

         import matplotlib.pyplot as plt

         plt.plot(xf, yf)

Out[41]: [<matplotlib.lines.Line2D at 0x1138adfd0>]
```

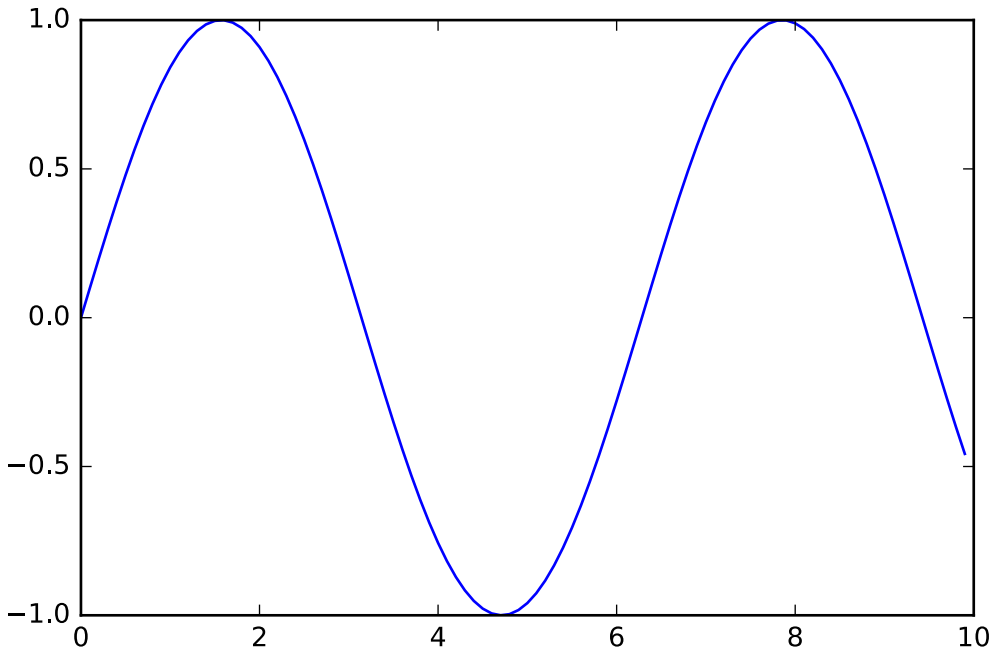

Ara és possible llegir els fitxers escrits.